Eksploracja danych

Ćwiczenia nr 2

Zad. 1 W pliku bank marketing training beda nas interesować następujące predyktory:

- age wiek,
- previous_outcome poprzednia odpowiedź,

oraz zmienna celu:

• response – odpowiedź.

Wykonaj poniższe polecenia kolejno w R i Pythonie:

- 1. Wczytaj plik.
- Sporządź zestawiony wykres słupkowy dla zmiennej previous_outcome, oznaczając kolorem wartości zmiennej response (odpowiedź). Następnie zrób znormalizowaną wersję tego wykresu.
- 3. Wykonaj tabelę krzyżową (kontyngencji) przedstawiającą łączny rozkład dwóch zmiennych: previous_outcome (w kolumnach) i response (w wierszach). W tabeli zamieść procenty liczone w kolumnach i zaokrąglone do 1 miejsca po przecinku.
- 4. Wykonaj zestawiony histogram dla zmiennej *age*, oznaczając kolorem wartości zmiennej *response* (odpowiedź). Następnie zrób znormalizowaną wersję tego wykresu.
- 5. Przekoduj zmienną age na nową zmienną age binned zgodnie ze schematem:
 - a. "Under 27", jeśli age<27,
 - b. ,,27 to 60", jeśli 27≤age≤60,
 - c. "Over 60", jeśli age>60.
- 6. Wykonaj zestawiony oraz zestawiony i znormalizowany wykres słupkowy dla zmiennej age_binned, oznaczając kolorem wartości zmiennej response (odpowiedź).

Zad. 2 Opis pliku Iris.csv

Plik zawiera dane o 150 kwiatach irysów. Poszczególne zmienne oznaczają:

- dlugosc_kielich długość działki kielicha,
- szerokosc kielich szerokość działki kielicha,
- dlugosc_platek długość płatka korony,
- szerokość platek szerokość płatka korony,
- *klasa* gatunek irysa (1 iris setosa, 2 iris versicolor, 3 iris virginica).

Wykonaj poniższe polecenia kolejno w R i Pythonie:

- a) Oblicz korelacje między wszystkimi zmiennymi. Z jaką zmienną najbardziej skorelowany jest gatunek irysa? Które z pozostałych zmiennych są ze sobą skorelowane?
- b) Wykonaj wykresy rozrzutu lub macierz wykresów, by zwizualizować zależność gatunku irysa od pozostałych zmiennych.
- c) Wykonaj trójwymiarowy wykres rozrzutu zależności gatunku irysa od długości kielicha i długości płatka.